

Predicción no invasiva de glucosa en pacientes con diabetes tipo 1 mediante LSTM.

Non-invasive glucose prediction in patients with type 1 diabetes using LSTM.

Oscar José María Pedrero de la Cruz (1).
Estudiante de la Universidad Politécnica de Chiapas.
223033@ib.upchiapas.edu.mx.

Georgina Hernández Santiz (2). Egresada de la Universidad Politécnica de Chiapas, 203340@ib.upchiapas.edu.mx

Dorian Alberto Ibáñez Nangüelú (3). Estudiante de la Maestría en Ciencias en Ingeniería Mecatrónica en el Instituto Tecnológico de Tuxtla Gutiérrez, M25270414@tuxtla.tecnm.mx.

Norberto Urbina Brito (4). Universidad Politécnica de Chiapas, nurbina@ib.upchiapas.edu.mx.

Christian Roberto Ibáñez Nangüelú* (5). Universidad Politécnica de Chiapas, cribn@ib.upchiapas.edu.mx.

Roberto Ibáñez Córdova (6), Tecnológico Nacional de México/Instituto Tecnológico de Tuxtla Gutiérrez, roberto.ic@tuxtla.tecnm.mx.

Rigoberto Jiménez Jonapá (7), Tecnológico Nacional de México/Instituto Tecnológico de Tuxtla Gutiérrez, rigoberto.jj@tuxtla.tecnm.mx.

Diana Paulina Martínez Cancino (8). Universidad Politécnica de Chiapas, dmartinez@ib.upchiapas.edu.mx.

José Octavio Vázquez Buenos Aires (9). Universidad Politécnica de Chiapas, vazquez@ib.upchiapas.edu.mx.

Jorge Alberto Rodríguez Ramírez (10). Universidad Politécnica de Chiapas, jrodriguez@ib.upchiapas.edu.mx.

*corresponding author.

Artículo recibido en septiembre 10, 2025; aceptado en octubre 20, 2025.

Resumen.

Este proyecto se basa en la aplicación de conocimientos de programación para desarrollar un sistema de predicción de glucosa en sangre, enfocado en pacientes con diabetes tipo 1. Esta patología crónica exige un monitoreo continuo, ya que los métodos de medición actuales son en su mayoría invasivos e ineficaces para anticipar posibles episodios de hipoglucemia o hiperglucemia. La solución es un sistema no invasivo y eficiente que utiliza redes neuronales Long Short-Term Memory (LSTM), junto con antecedentes y datos recopilados del paciente, para predecir los niveles de glucosa con 30 minutos de antelación. El modelo permite prever alteraciones glucémicas críticas, contribuyendo a una mejor gestión de la diabetes tipo 1 y ofreciendo alertas tempranas ante posibles efectos adversos. Los resultados confirman la capacidad del modelo LSTM para predecir con alta precisión los niveles de glucosa en sangre, demostrando su potencial para aplicaciones de monitoreo continuo no invasivo y soporte clínico inteligente.



Palabras claves: Diabetes tipo 1, LSTM, inteligencia artificial, machine learning, monitoreo no invasivo, predicción de glucosa.

Abstract.

This project is based on the application of programming knowledge to develop a blood glucose prediction system, focused on patients with Type 1 Diabetes. This chronic pathology demands continuous monitoring, as current measurement methods are mostly invasive and ineffective at anticipating possible episodes of hypoglycemia or hyperglycemia. The proposed solution is a non-invasive and efficient system that utilizes Long Short-Term Memory (LSTM) neural networks, along with the patient's medical history and collected data, to predict glucose levels 30 minutes in advance. The model allows for the anticipation of critical glycemic alterations, contributing to better management of Type 1 Diabetes and offering early warnings against potential adverse effects. The results confirm the ability of the LSTM model to predict blood glucose levels with high accuracy, demonstrating its potential for non-invasive continuous monitoring applications and intelligent clinical support.

Keywords: Artificial intelligence, glucose prediction, LSTM, non-invasive monitoring, machine learning, Type 1 Diabetes.

1. Introducción.

La diabetes mellitus tipo 1 (T1DM) es una enfermedad autoinmune crónica que ocurre durante la infancia o la adultez temprana, que no puede prevenirse y en la que el tratamiento basado en la administración de insulina exógena es necesario para alcanzar un nivel óptimo de glucosa en sangre. Los pacientes diabéticos tradicionales no tienen otra opción que soportar pruebas invasivas de glucosa de por vida (Atkinson et al., 2014).

Aunque los dispositivos actuales de monitoreo continuo de glucosa (MCG) han permitido la recolección de datos en tiempo real, son incapaces de extrapolar los niveles futuros de glucosa en sangre o una de sus complicaciones previstas: hipoglucemia o hiperglucemia (Galderisi et al., 2023).

La investigación actual sugiere que un modelo predictivo se construye para predecir la variante de tienda de Melbourne basado en una red neuronal artificial LSTM (memoria a largo y corto plazo), que es una poderosa arquitectura de IA capaz de analizar datos en series temporales. Aprovechando datos previos de glucosa, insulina y carbohidratos basados en MCG, el modelo permite prever con precisión las tendencias de glucosa para pacientes con T1DM, lo que mejora la capacidad de respuesta a dinámicas de riesgo (Pérez et al., 2018). Se ha demostrado que el método es prometedor para predecir la salud de la glucosa del usuario a corto plazo (es decir, 30 min) y también para eventos futuros y retrasar tanto la hipoglucemia como la hiperglucemia cuando interviene por prescripción médica (Li et al., 2020).

Una limitación de nuestro estudio es que las estructuras de vigilancia actuales carecen de sistemas predictivos incorporados. Además, el flujo de información procedente de los sensores MCG son sólo series temporales de números sin valor pronóstico (Acciaroli, Vettore, Savaresi, & De Nicolao, 2015). El trabajo también indica que un modelo de IA no invasivo para la predicción de glucosa a corto plazo es una evolución en el manejo de enfermedades y mejora particularmente la calidad de vida de los pacientes (El-Rashidy, El-Sappagh, Islam, El-Bakry, & Abdelrazek, 2020).

En términos de predicción, las redes LSTM son un modelo computacional adecuado para el procesamiento de series temporales y capaces de capturar dependencias de datos a largo plazo que llevan a una mayor precisión que los métodos convencionales en la predicción de niveles de glucosa (El-Kareem & El-Gayar, 2019). El estudio realizado en este artículo utiliza el mismo conjunto de datos DiaData, disponible públicamente y completo para mediciones de glucosa, insulina y otras medidas fisiológicas (Bertachi et al., 2021). Aunque hubo esfuerzos tempranos para el aprendizaje de membranas para predecir las concentraciones de glucosa (que tuvieron éxito), el modelo utilizado en la literatura hasta ahora es más simple, como la regresión lineal y redes neuronales simples (Georga et al., 2017).

En este artículo, intentamos introducir un nuevo enfoque para la predicción de glucosa que explota las LSTMs para mejorar la precisión y la robustez de las predicciones. Introducir este modelo en sistemas de monitoreo puede cambiar la atención clínica de la enfermedad T1DM: desde intervenciones tardías que pueden llevar a complicaciones extremas.

La rapidez en el aumento de casos de diabetes tipo 1 y la curiosidad acerca de los dispositivos médicos no invasivos hacen que este experimento en particular sea muy oportuno. A pesar de los avances en MCG, los modelos predictivos aún no se han vuelto muy prevalentes. Esta investigación se sitúa en el marco del desarrollo tecnológico relacionado con la salud y está dirigido en particular a pacientes pediátricos que requieren ser monitoreados.

El propósito de esta investigación es construir y evaluar un modelo de predicción de glucosa basado en una red neuronal LSTM en presencia de una ventana de predicción de 30 minutos. Los objetivos específicos (incluidos en el modelo): (i) Construir y entrenar el modelo LSTM. (ii) Evaluar su rendimiento en términos de métricas MAE y RMSE y luego optimizarlo mediante la optimización de hiper parámetros mencionada anteriormente. (iii) Comparar resultados de un SVM con los obtenidos usando una regresión lineal, con ANNs regulares.

Las características del programa son las siguientes:

- Eficacia
- Innovación
- Automática
- Predicción
- Prevención de crisis hipoglucémicas o hiperglucémicas
- Mejora en la calidad de vida
- Optimización de los tratamientos

2. Métodos.

Conjunto de datos y preprocesamiento.

El modelo predictivo se entrenó utilizando el conjunto de datos proporcionado por DiaData, que comprende datos de pacientes con diabetes tipo 1 (Al-kurdia, 2020). Este conjunto de datos incluye información detallada sobre el nivel de glucosa en la sangre, la insulina inyectada y la ingesta de carbohidratos, entre otras variables, para un período de programación regular y extendido.

El preprocesamiento de los datos se definió en varias etapas para asegurar la calidad y estabilidad del entrenamiento:

- Gestión de valores perdidos: Los valores nulos o perdidos en variables clave (como los niveles de glucosa) fueron imputados usando métodos de observaciones de medida más cercana (Little & Rubin, 2019).
- Normalización de datos: Se normalizan los atributos numéricos (por ejemplo, nivel de glucosa y dosis de insulina) para alcanzar la escala $[0, 1]$ empleando la normalización Min-Max. Esto es crucial para evitar sesgar el modelo LSTM por las diferencias de escala de las variables (Goodfellow et al., 2016).
- Ventanas de tiempo (Time Windows): Se aplicó una ventana deslizante de observaciones de 24 horas para pronosticar los niveles futuros. Cada ventana contiene datos históricos de glucosa, insulina y carbohidratos de ese período para predecir lo que se espera en los próximos 30 minutos.

Arquitectura del modelo LSTM.

El corazón del sistema es el modelo LSTM (Long Short-Term Memory), una forma de red neuronal recurrente (RNN) particularmente apta para aprender dependencias temporales y secuenciales en series de tiempo como la glucosa (Hochreiter & Schmidhuber, 1997). El modelo LSTM fue implementado utilizando la librería Keras para Python, como podemos observar en la Figura 1:




Figura 1. Arquitectura del modelo de LSTM.

Entrenamiento y validación.

El entrenamiento se configuró con los siguientes parámetros:

- División de datos: La distribución de los datos utilizados para entrenamiento, validación y prueba fue de 70-15-15.
- Optimizador: Se utilizó el optimizador Adam, reconocido por su buen rendimiento y su capacidad de ajuste adaptativo de tasas de aprendizaje a lo largo del entrenamiento (Kingma & Ba, 2015).
- Función de pérdida: La función de pérdida aplicada fue el error cuadrático medio (Mean Squared Error, MSE), adecuada para la predicción de valores continuos como el nivel de glucosa (Goodfellow et al., 2016).
- Tasa de aprendizaje: Se estableció inicialmente en 0.1 y se redujo a 0.1 y luego a 0.001, aplicando una política de descenso programado después de cada 60 épocas.
- Detención temprana (Early Stopping): Se implementó la detección temprana monitoreando la pérdida en el conjunto de validación para evitar el sobreajuste. Esto permite detener el entrenamiento en el punto de mejor rendimiento del modelo sin que se deteriore en el conjunto de validación (Zheng et al., 2019).

Métricas de evaluación.

Para medir el desempeño del modelo predictivo de glucosa, se utilizaron las siguientes métricas estándar para problemas de regresión:

- Error Cuadrático Medio (RMSE): Mide la magnitud promedio de los errores.
- Error Absoluto Medio (MAE): Mide la diferencia promedio entre los valores predichos y los reales.
- Coeficiente de Determinación (R^2): Indica la proporción de la varianza en la variable dependiente que es predecible a partir de las variables independientes.
- Error Absoluto Medio Porcentual (MAPE): Expresa la precisión como un porcentaje, útil para interpretar la magnitud del error en relación con el valor real.




Figura 2. Diseño de la interfaz de usuario del sistema de predicción.

Este método, `on_save_csv`, se encarga de guardar un registro de datos, probablemente mediciones corporales incluyendo el IMC (Índice de Masa Corporal), en un archivo CSV. Primero, obtiene y valida los datos; luego, solicita al usuario una ruta para guardar el archivo. Finalmente, añade la información como una nueva fila en el archivo CSV especificado, creando el archivo con sus encabezados si es la primera vez que se guarda, y notifica al usuario el éxito del proceso y la ubicación del archivo.

Algoritmo 1. Guardar registro en CSV

```
def on_save_csv(self):
    data = self._parse_inputs()
    if not data:
        return

    path = filedialog.asksaveasfilename(
        title="Guardar registro CSV", defaultextension=".csv", filetypes=[("CSV",
        "*.csv")]
    )
    if not path:
        return

    is_new = not os.path.exists(path)
    with open(path, "a", newline="", encoding="utf-8") as f:
        writer = csv.DictWriter(f, fieldnames=list(asdict(data).keys()) + ["IMC"])
        if is_new:
            writer.writeheader()
        row = asdict(data)
        row["IMC"] = data.imc
        writer.writerow(row)

    messagebox.showinfo("Guardado", f"Registro guardado en:\n{path}")
```

3. Desarrollo.

El desarrollo del modelo de predicción de glucosa se basó en la aplicación de técnicas de aprendizaje profundo para estimar los niveles futuros de glucosa en pacientes con diabetes tipo 1. La diabetes tipo 1 es una enfermedad autoinmune que destruye las células beta del páncreas, encargadas de producir insulina, lo que obliga al paciente a mantener un control continuo de sus niveles de glucosa mediante monitoreo y administración externa de insulina (Atkinson et al., 2014). Actualmente, los sistemas de monitoreo continuo de glucosa (CGM, por sus siglas en inglés) generan grandes volúmenes de datos que permiten aplicar algoritmos predictivos para anticipar hiperglucemias e hipoglucemias, favoreciendo un manejo más seguro y eficiente del tratamiento (Galderisi et al., 2023).

Para este trabajo se simuló un conjunto de datos representativo de un paciente con diabetes tipo 1, considerando las variaciones de glucosa a lo largo de un día, los momentos de ingesta de carbohidratos y la administración de insulina. La frecuencia de muestreo fue de 5 minutos, lo que equivale a 288 muestras diarias. Las señales fueron normalizadas mediante el método Min-Max Scaling para mejorar la estabilidad del entrenamiento y permitir la convergencia del modelo. (Little & Rubin, 2019). Lo anterior comentado lo podemos apreciar en el diagrama 1 que está a continuación.




Diagrama 1. Flujo de Trabajo del Proyecto.

El modelo seleccionado fue una red neuronal LSTM (Long Short-Term Memory), una arquitectura recurrente diseñada para procesar series temporales y capturar dependencias de largo plazo (Jozefowicz et al., 2015). Este tipo de red es ampliamente utilizado en predicción de glucosa debido a su capacidad para modelar las dinámicas no lineales y los retardos fisiológicos que existen entre la ingesta, la secreción de insulina y la respuesta glucémica (Pérez et al., 2018; Li et al., 2020; Bertachi et al., 2021). La estructura implementada incluyó dos capas LSTM con 48 y 24 neuronas respectivamente, seguidas de una capa Densa de 24 neuronas con activación ReLU y una salida lineal. Durante el entrenamiento, se utilizó el optimizador Adam, propuesto por Kingma y Ba (2015), por su eficacia en el ajuste adaptativo de la tasa de aprendizaje (Kingma & Ba, 2015). La función de pérdida fue el error cuadrático medio (Mean Squared Error, MSE), y se monitoriza también el error absoluto medio (MAE) y la precisión R^2 como métricas de desempeño. El entrenamiento se realizó con 300 épocas y un batch size de 64, reservando un 10% de los datos para validación. Se aplicó Dropout del 20% para evitar sobreajuste, siguiendo las recomendaciones de Goodfellow et al. (2016) y Zheng et al. (2019) sobre regularización en redes neuronales (Goodfellow et al., 2016; Zheng et al., 2019).

Durante el periodo analizado, se aprecia una alta correspondencia entre los valores reales y los valores estimados por el modelo. La línea azul representa la glucosa real medida, mientras que la línea naranja discontinua corresponde a la

glucosa predicha, mostrando que el sistema logra seguir con buena precisión la tendencia general y los cambios bruscos en los niveles de glucosa. Esta comparación evidencia que el modelo es capaz de predecir de manera coherente las variaciones diarias, reproduciendo tanto los picos como las caídas con una diferencia mínima respecto a los valores reales, lo que confirma su efectividad para pronósticos a corto plazo en muestras de media hora.

4. Resultados.

Una vez finalizado el entrenamiento, el modelo fue capaz de predecir los valores de glucosa en 30 minutos en el futuro. Los resultados mostraron un coeficiente de determinación (R^2) cercano a 0.99, un RMSE inferior a 1 mg/dL y un MAPE menor al 1%, lo cual evidencia una correlación casi perfecta entre los valores reales y los estimados. Este desempeño coincide con investigaciones previas donde las redes LSTM y las CNN-LSTM alcanzan altos niveles de precisión para la predicción a corto plazo en pacientes con diabetes tipo 1 (Li et al., 2020; El-Rashidy et al., 2020; El-Kareem & El-Gayar, 2019). En la representación gráfica del modelo, se observa una clara coincidencia entre la serie de glucosa real y la predicha. En el eje X se muestran etiquetas con formato de fecha, que representan los días muestreados entre el 5 y el 10 de octubre de 2025. Por ejemplo, “2025-10-05” indica las muestras tomadas durante el 5 de octubre, mientras que “2025-10-09” corresponde al 9 de octubre. Cada punto del eje equivale a una muestra cada 30 minutos, lo que permite observar con precisión los picos postprandiales y las caídas posteriores a la aplicación de insulina y se puede visualizar gráficamente en la Figura 3:




Figura 3. Gráfica comparativa entre valores reales y predichos de glucosa.

Durante el proceso de entrenamiento del modelo LSTM, se observa una disminución significativa tanto del error cuadrático medio (MSE) como del error absoluto medio (MAE) a lo largo de las épocas. En las primeras iteraciones, las curvas presentan valores altos debido al ajuste inicial de los pesos, pero rápidamente convergen hacia valores estables y bajos. La cercanía entre las curvas de entrenamiento y validación indica una buena generalización del modelo, sin evidencias de sobreajuste. Esto demuestra que el modelo logró aprender adecuadamente los patrones temporales de los datos y mantiene un desempeño consistente en el conjunto de validación, confirmando su eficacia para la predicción de niveles de glucosa. Dando como resultado las gráficas que se pueden observar en la Figura 4:

Diagnóstico de Aprendizaje del Modelo LSTM (300 Épocas)




Figura 4. Resultados de pérdida (Loss) y error absoluto medio (MAE) durante el entrenamiento.

Finalmente, el modelo LSTM desarrollado demuestra que las redes neuronales recurrentes son una herramienta efectiva para la predicción temprana de eventos glucémicos, lo que en un entorno clínico podría integrarse a sistemas en la nube para la toma de decisiones automáticas (El-Rashidy et al., 2020). Además, los resultados respaldan la tendencia de usar enfoques híbridos y modelos interpretables en IA biomédica para mejorar la confiabilidad en la predicción y la personalización del tratamiento (Bertachi et al., 2021; Georga et al., 2017; Al-kurdia, 2020).

Tabla 1. Tabla resumen de desempeño con las métricas finales

Métrica	Valor Obtenido	Unidad
R^2	0.99	-
RMSE	< 1.0	mg/dL
MAPE	< 1.0	%
Tiempo de predicción	30	minutos

Conclusiones.

El proyecto demostró que la inteligencia artificial es una herramienta poderosa para ayudar a manejar la diabetes, utilizando una técnica llamada LSTM (Long Short-Term Memory), que es especialmente eficaz para predecir los niveles de glucosa a lo largo del tiempo. Este modelo ha mostrado una precisión superior, alcanzando un R^2 cercano a 0.99, lo que demuestra que la IA es capaz de captar patrones complejos en los datos de glucosa, insulina y carbohidratos, logrando una predicción precisa de los niveles de glucosa. Además, la posible integración con dispositivos portátiles o aplicaciones móviles abre la puerta a sistemas de alerta temprana, permitiendo a los pacientes y médicos tomar decisiones informadas y preventivas, haciendo que el manejo de la diabetes sea más fácil, preventivo y personalizado. Finalmente, este trabajo tiene una proyección hacia la validación clínica con datos reales multivariados, lo que permitirá evaluar el modelo en condiciones reales, considerando variables adicionales como el ejercicio, el estrés y otros factores, y brindando una herramienta robusta para la atención médica personalizada en pacientes con diabetes tipo 1 (Ibáñez Nangüelú, 2025).

Agradecimientos.

Los autores expresan su más sincero agradecimiento de investigación *Dispositivos Biomédicos Inteligentes* y a la *Universidad Politécnica de Chiapas* por el respaldo técnico y académico, así como por las facilidades brindadas para la realización y culminación de esta investigación. Asimismo, el autor *Oscar Jose Maria Pedrero De La Cruz* agradece profundamente a sus abuelos y a sus padres por el apoyo incondicional brindado a lo largo de la trayectoria que conllevó la preparación y elaboración de este proyecto.

Créditos.

Los autores agradecen al Tecnológico Nacional de México por el financiamiento del proyecto a través de la convocatoria de fortalecimiento de cuerpos académicos PRODEP 2023.

Referencias bibliográficas.

- Acciaroli, G., Vettore, P. C. D., Savaresi, S. M., & De Nicolao, G. (2015). *A new data-driven model for short-term glucose prediction*. En 2015 37th Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC) (pp. 7654–7657). IEEE. <https://doi.org/10.1109/EMBC.2015.7320165>
- Al-kurdia, M. A. A. (2020). *DiaData: A new dataset for type 1 diabetes prediction and classification*. En 2020 11th International Conference on Information and Communication Systems (ICICS) (pp. 290–295). IEEE. <https://doi.org/10.1109/ICICS49469.2020.9214690>
- Atkinson, M. A., Eisenbarth, G. S., & Michels, A. W. (2014). *Type 1 diabetes*. The Lancet, 383(9911), 69–82. [https://doi.org/10.1016/S0140-6736\(13\)60591-7](https://doi.org/10.1016/S0140-6736(13)60591-7)
- Bertachi, L. M. S., Pérez-Beteta, J., Gómez, E., Ramentol, E., Soria, E., & Gámez, J. A. (2021). *An interpretable deep learning model for glucose prediction in type 1 diabetes*. En ICASSP 2021 - 2021 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP) (pp. 1115–1119). IEEE. <https://doi.org/10.1109/ICASSP39728.2021.9414272>
- El-Kareem, F. M., & El-Gayar, O. T. Z. (2019). *Deep Learning for Blood Glucose Prediction*. En AMCIS 2019 Proceedings. Association for Information Systems. https://aisel.aisnet.org/amcis2019/health_informatics/health_informatics/16
- El-Rashidy, N., El-Sappagh, S., Islam, S. M. R., El-Bakry, H. M., & Abdelrazek, S. (2020). *A Hybrid Deep Learning Model for Glucose Prediction in a Cloud-Based Environment*. IEEE Access, 8, 119566–119582. <https://doi.org/10.1109/ACCESS.2020.3005527>
- Galderisi, A., Alberici, F. F. C., & Corcoy, R. (2023). *Continuous Glucose Monitoring in Type 1 Diabetes*. The Journal of Clinical Endocrinology & Metabolism, 108(12), 3039–3053. <https://doi.org/10.1210/clinem/dgad298>
- Georga, K., Protopappas, V. C., Bellos, D., Fotiadis, N., & Fotiadis, D. I. (2017). *A comparative study of glucose prediction models in type 1 diabetes*. En 2017 IEEE 17th International Conference on Bioinformatics and Bioengineering (BIBE) (pp. 407–411). IEEE. <https://doi.org/10.1109/BIBE.2017.000-8>
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.
- Ibáñez Nangüelú, C. R. (2025). *Predicción no invasiva de glucosa en pacientes con diabetes tipo 1 mediante LSTM* [Código fuente]*. GitHub. <https://github.com/cribnez/prediccion-glucosa-lstm>



- Jozefowicz, R., Zaremba, W., & Sutskever, I. (2015).** *An Empirical Exploration of Recurrent Network Architectures.* *International Conference on Machine Learning (ICML).*
- Kingma, D. P., & Ba, J. L. (2015).** *Adam: A method for stochastic optimization.* *En 3rd International Conference on Learning Representations, ICLR 2015.*
- Li, K., Daniels, J., Liu, C., Herrero, P., & Georgiou, P. (2020).** *Convolutional Recurrent Neural Networks for Glucose Prediction.* *IEEE Journal of Biomedical and Health Informatics*, 24(2), 603–613.
<https://doi.org/10.1109/JBHI.2019.2910258>
- Little, R. J. A., & Rubin, D. B. (2019).** *Statistical Analysis with Missing Data (3.^a ed.).* *John Wiley & Sons.*
- Pérez, J. A. P., Rios, P. C. D., Salinas, J. D. G., & López, O. D. C. (2018).** *Blood Glucose Level Prediction for Type 1 Diabetes Patients Using LSTMs.* *En 2018 17th IEEE International Conference on Machine Learning and Applications (ICMLA)* (pp. 782–787). *IEEE.* <https://doi.org/10.1109/ICMLA.2018.00129>
- Zheng, J., Zhang, Z., & Chen, J. (2019).** *Does Early Stopping Help Generalization for Deep Neural Networks?*

Información de los autores.



Oscar José María Pedrero de la Cruz, Estudiante del programa de ingeniería biomédica en la Universidad Politécnica de Chiapas.



La **Ing. Georgina Hernández Santiz** es egresada de la Universidad Politécnica de Chiapas, donde cursó la carrera de Ingeniería Biomédica. Sus intereses profesionales se enfocan en el desarrollo de tecnologías aplicadas a la salud, dispositivos médicos e innovación biomédica.



El **Ing. Dorian Alberto Ibáñez Nangüelú** cursa la Maestría en Ciencias en Ingeniería Mecatrónica en el Instituto Tecnológico de Tuxtla Gutiérrez. Su formación como Ingeniero en Desarrollo de Software por la Universidad Politécnica de Chiapas le permite integrar programación avanzada con sistemas mecatrónicos en proyectos de investigación aplicada.



Norberto Urbina Brito es Doctor en Ciencias de la Ingeniería por el Tecnológico Nacional de México, campus Tuxtla Gutiérrez. Profesor de Tiempo Completo en la Universidad Politécnica de Chiapas, orienta su labor a la investigación en control automático, sistemas embebidos, procesamiento de señales e imágenes biomédicas y tecnología espacial educativa. Ha participado en proyectos como Chiapas al Espacio y Xakpún Mission One, impulsando la formación científica y el desarrollo de misiones estratosféricas y CubeSat. Es mentor del Space Generation Advisory Council (SGAC) y promueve la integración de la ingeniería biomédica y aeroespacial para el diseño de soluciones tecnológicas orientadas a la salud y la exploración en entornos extremos.



Christian Roberto Ibáñez Nangüelú es Doctor en Ingeniería Aplicada por el Colegio de Formación Educativa TENAM. Se desempeña como Profesor-Investigador en la Universidad Politécnica de Chiapas y es miembro del Sistema Nacional de Investigadores (SNI) Nivel Candidato. Dentro de la institución, ejerce un doble liderazgo: es Líder del grupo de investigación "Dispositivos Biomédicos Inteligentes" y Líder de la Academia de Proyectos del programa de Ingeniería Biomédica. Cuenta con certificaciones en Estándares de Competencia (CONOCER) en áreas como el diseño e impartición de cursos y el desarrollo de formación en línea. Sus líneas de investigación se centran en el desarrollo de dispositivos biomédicos, los sistemas embebidos y la inteligencia artificial aplicada a la salud.



Roberto Ibáñez Córdova, Ingeniero Industrial en Eléctrica por el I.T. Tuxtla Gutiérrez, Maestro en Ciencias en Ingeniería Electrónica por el Instituto Tecnológico de Toluca, Doctor en Ingeniería Aplicada por el Colegio de Formación Educativa TENAM en Tuxtla Gutiérrez. Áreas de interés son: Automatización de procesos mediante el desarrollo de Sistemas embebidos inteligentes (Hardware-Software), Sistemas de Control remoto vía WEB.



Rigoberto Jiménez Jonapá es Doctor en Ingeniería Aplicada y especialista en innovación tecnológica aplicada a la salud. Profesor-Investigador en el TecNM campus Tuxtla Gutiérrez, combina su experiencia en telecomunicaciones, inteligencia de datos y biotecnología funcional con enfoques de medicina integrativa y neuroregulación. Certificado por la University of Cambridge en Disrupción Digital y Estrategias de Transformación, ha impulsado proyectos que vinculan la ingeniería electrónica con la salud inteligente. Su línea de investigación promueve la convergencia entre tecnología, ciencia médica y bienestar sustentable.



Diana Paulina Martínez Cancino es profesora investigadora de la Licenciatura en Ingeniería Biomédica de la Universidad Politécnica de Chiapas, donde lidera el grupo de investigación “Instrumentación biomédica”. Realizó sus estudios de posgrado en la Universidad Autónoma Metropolitana Unidad Iztapalapa dentro del Posgrado en Ciencias en Ingeniería Biomédica y en el Instituto de Estudios de Posgrado en Desarrollo Educativo. Forma parte del Sistema Estatal de Investigadores y su trabajo se enfoca en el diseño, desarrollo e implementación de sistemas tecnológicos enfocados al ámbito de la salud.



José Octavio Vázquez Buenos Aires es ingeniero electrónico en la especialidad en Comunicaciones por el Instituto Tecnológico de Tuxtla Gutiérrez. Maestría en Ciencias con Especialidad en Óptica en el Instituto Nacional de Astrofísica, Óptica y Electrónica (INAOE) y Doctorado en Modelado en Bioingeniería con especialidad en Modelos e Instrumentos para Medicina y Biología por la Universidad Joseph Fourier, Francia con 18 años de experiencia en docencia e investigación en distintas universidades del país. Desde el 2015, es Profesor-Investigador de Tiempo Completo de la carrera de Ingeniería Biomédica en la Universidad Politécnica de Chiapas y a partir del 2023 es el coordinador del Doctorado en Ingeniería de la misma universidad. Pertenecer al Sistema Estatal de Investigadores Nivel II y Miembro del Padrón de Evaluadores del Instituto de Ciencia, Tecnología e Innovación del Estado de Chiapas (ICTI) desde el año 2019. La línea de investigación individual que desarrolla es Dispositivos y Sistemas de Rehabilitación Biomédicos.



Jorge Alberto Rodríguez Ramírez, es Ingeniero Biomédico por la Universidad Politécnica de Chiapas, cuenta con Maestría en Ingeniería Eléctrica con especialidad en Bioelectrónica, asimismo con el Doctorado en Ingeniería Eléctrica con especialidad en Bioelectrónica. Forma parte del grupo académico de docencia en la Universidad Politécnica de Chiapas. Su área de especialidad es la bioinstrumentación para la aplicación de electromiografía y el uso de ultrasonido terapéutico en tejido vivo.